

Relatório Técnico

Mineração de Dados — Pitch Intelligence

Universidade de Marília (UNIMAR)

Integrante 1 Sobrenome1 | Integrante 2 Sobrenome2

Sistema de apoio à decisão para convocações da Copa do Mundo FIFA 2026, integrando dados do FBref (Big 5 + Brasileirão) e valor de mercado do Transfermarkt.

1. Introdução

A startup fictícia Pitch Intelligence foi contratada por uma federação nacional para desenvolver um pipeline de inteligência esportiva. O objetivo pedagógico deste trabalho é percorrer todas as etapas de um projeto real de mineração de dados: coleta, integração, limpeza, exploração, modelagem e interpretação.

O dataset combina estatísticas de 2.953 jogadores das cinco maiores ligas europeias e do Campeonato Brasileiro (temporada 2025-26), enriquecidas com valor de mercado do Transfermarkt para os ~500 jogadores mais valiosos do mundo.

2. Etapa 1 — Construção da Base de Dados

Fonte 1 (FBref): arquivo fbref_big5_brasileirao_2526_V2.csv carregado com pandas, contendo 123 colunas (FBref + FotMob). Fonte 2 (Transfermarkt): raspagem de 8 páginas com BeautifulSoup e requests, respeitando User-Agent e pausa de 2 segundos entre páginas.


Desafios: (1) normalização de nomes com unicodedata e remoção de acentos para o merge; (2) conversão de valores como '€ 200.00 mi.' para float em euros; (3) cobertura parcial do Transfermarkt (~6,7% dos jogadores FBref).

Estatísticas do merge:


- Jogadores FBref (base): 2.953
- Jogadores Transfermarkt: 200
- Com valor de mercado: 197 (6,7%)
- Validação HTML goleiros Brasileiro: 33 (HTML) vs 32 (CSV)

3. Etapa 2 — Pré-processamento e EDA


Posição simplificada pela primeira sigla (ex.: 'DF,MF' → DF). Estatísticas posicionais ausentes foram preenchidas com 0 (goleiro sem xG, atacante sem defesas). xG e avaliação FotMob ausentes foram imputados pela mediana da posição.




Interpretação: apenas 6,7% dos jogadores possuem valor no Transfermarkt (top mundial). A mediana reflete o mercado de elite — jogadores abaixo dessa faixa podem ser oportunidades subvalorizadas para a federação.




Interpretação: atacantes concentram gols e xG; meias lideram em volume defensivo (interceptações); a separação por posição valida a estratégia de zeros posicionais.



Interpretação: nacionalidades europeias e sul-americanas dominam o valor médio, refletindo concentração de talentos nas Big 5.




Interpretação: Big5 e Brasileiro têm medianas de minutos comparáveis, mas o Brasileiro pode ter mais ausências em stats avançadas (cobertura Opta menor).



Interpretação: gols e xG correlacionam fortemente; métricas de goleiro são ortogonais às ofensivas, favorecendo separação em clusters.


4. Etapa 3 — Clusterização

K-Means com StandardScaler sobre 15 features (incluindo zeros posicionais). Escolha de k=3 via Silhouette Score (complementado pelo método do cotovelo).



Cluster	Nome	N	Gols	xG	Min	Defesas GK	Valor médio (Mi)
0	Meias/Rotacionados	2403	0.8	0.9	1009	0.7	56.5
1	Atacantes/Ofensivos	439	6.5	6.2	2019	0.0	72.8
2	Goleiros	111	0.0	0.0	2489	79.2	43.3

Cluster 0 (Meias/Rotacionados): 2.403 jogadores, ~1.009 min, poucos gols — elenco de rotação. Cluster 1 (Atacantes/Ofensivos): 439 jogadores, ~2.019 min, 6,5 gols e 6,3 xG. Cluster 2 (Goleiros): 111 jogadores, 79 defesas e 7,6 clean sheets em média.





5. Etapa 4 — Classificação

Target binário: minutos > mediana (1.025) = Titular Regular (1) vs Rotação/Reserva (0). Classes balanceadas (~50/50). Excluídos das features: minutos, 90s, starts, valor_mercado.

Modelos: Random Forest e Regressão Logística com class_weight='balanced' e StratifiedKfold (k=5).

Modelo	Acurácia	Precisão	Recall	F1-Score
Random Forest	0.9268	0.9290	0.9248	0.9266
Regressão Logística	0.9265	0.9345	0.9173	0.9257



A variável 'jogos' (partidas disputadas) é a mais importante (33%), correlacionando fortemente com minutos — o que pode inflacionar as métricas (~92%). Isso deve ser considerado como limitação metodológica.

Reflexão Precisão vs Recall: falso negativo (titular não identificado) é mais crítico para a Copa do Mundo do que falso positivo — priorizar Recall na escolha do modelo.

6. Etapa 5 — Recomendação Estratégica

Um elenco equilibrado para a Copa deve combinar os três perfis identificados: goleiros titulares (Cluster 2), meias/defensores de volume (Cluster 0) e atacantes ofensivos (Cluster 1).

Jogadores citados (Nível Copa):

- Akor Adams (Sevilla, FW): 1.947 min, 10 gols, xG 10,0, cluster Atacantes, probabilidade titular 100%. Contribuição ofensiva consistente com alta expectativa de gols.
- Michel Aebischer (Pisa, MF): 2.742 min, 33 intercepções, titular regular apesar do perfil de rotação — volume defensivo elevado.
- Fábio (Fluminense, GK): 1.350 min, cluster Goleiros — referência do Brasileirão para análise do mercado local.

7. Limitações

- Target proxy (minutos) não captura qualidade tática ou momento de forma.
- Merge Transfermarkt cobre apenas 6,7% dos jogadores.
- Feature 'jogos' correlacionada com target pode inflacionar acurácia.
- Ausência de dados de lesões, vídeo e scouting subjetivo.
- Cobertura Opta menor no Brasileirão pode enviesar comparações.

8. Conclusão

O pipeline integra com sucesso dados heterogêneos, identifica perfis táticos via clusterização não supervisionada e classifica jogadores como titulares regulares com acurácia superior a 92%. As visualizações e métricas fornecem subsídio concreto para decisões de convocação, reconhecendo limitações que um sistema profissional de scouting deveria complementar.