

Otimização de Diagnóstico em Telemedicina: Comparativo de Árvore de Decisão, Naive Bayes e KNN no Dataset Pima Indians Diabetes

Jesus Gabriel Leiva

Pós-graduação em Ciência de Dados e Inteligência Artificial — Caso 01: IA e ciência de dados na saúde

Autor para correspondência: jesusgabrielleiva1@gmail.com

Resumo

Este trabalho apresenta um experimento comparativo de aprendizado de máquina clássico para apoio ao diagnóstico precoce de diabetes, utilizando o dataset Pima Indians Diabetes. Foram avaliados Árvore de Decisão, Naive Bayes Gaussiano e K-Nearest Neighbors (KNN), com validação cruzada estratificada (K=10) e otimização de hiperparâmetros orientada ao Recall, priorizando a redução de falsos negativos — custo clínico crítico em telemedicina. Zeros fisiologicamente inconsistentes foram tratados como valores ausentes e imputados por mediana dentro de pipelines, evitando vazamento de informação. A Árvore de Decisão (critério Gini, profundidade máxima 4) obteve o melhor compromisso entre sensibilidade e estabilidade (Recall médio de 0,675 no CV; Recall 0,722, F1 0,709 e AUC 0,805 no hold-out), sendo recomendada para integração ao sistema, sobretudo por alinhar desempenho preditivo à interpretabilidade exigida no setor de saúde.

Abstract

This paper presents a comparative classical machine learning experiment to support early diabetes diagnosis using the Pima Indians Diabetes dataset. Decision Tree, Gaussian Naive Bayes and K-Nearest Neighbors were evaluated with stratified 10-fold cross-validation and recall-oriented hyperparameter tuning, prioritizing false-negative reduction — a critical clinical cost in telemedicine. Physiologically implausible zeros were treated as missing values and median-imputed inside pipelines to prevent information leakage. The Decision Tree (Gini criterion, max depth 4) achieved the best trade-off between sensitivity and stability (mean CV recall 0.675; hold-out recall 0.722, F1 0.709 and AUC 0.805) and is recommended for production, balancing predictive performance with the interpretability required in healthcare.

Palavras-chaves: aprendizado de máquina; diabetes; árvore de decisão; naive bayes; KNN; validação cruzada; telemedicina.

1. Introdução

A MedTech Solutions demanda um classificador robusto para suporte ao diagnóstico em telemedicina, com ênfase em minimizar falsos negativos: deixar de identificar um paciente diabético implica risco clínico elevado. O conjunto Pima Indians Diabetes, do repositório UCI, contém 768 registros femininos com atributos clínicos contínuos (glicose, pressão arterial, IMC, insulina, espessura da pele, pedigrí de diabetes e idade) e o número de gestações, além do rótulo binário Outcome. Cerca de 34,9% das amostras pertencem à classe positiva, configurando

desbalanceamento moderado que motiva validação estratificada e métricas além da acurácia.

O experimento compara três famílias clássicas — Árvore de Decisão, Naive Bayes e KNN — documentando escolhas metodológicas, comportamento sob as condições dos dados e recomendação para produção, sem tratar os modelos como caixa-preta.

2. Metodologia de Validação

Dada a natureza finita do conjunto ($n=768$), adotou-se Stratified K-Fold Cross Validation com $K=10$. Esse valor é o padrão empírico para conjuntos de porte similar: cada fold de teste contém cerca de 77 amostras, o que estabiliza a estimativa sem reduzir excessivamente o conjunto de treino (como ocorreria em leave-one-out). A estratificação preserva a proporção das classes em cada partição, evitando folds atípicos da classe minoritária.

A validação cruzada mitiga o viés de um único particionamento arbitrário treino/teste e permite estimar a variância do erro de generalização (média $\pm$ desvio entre folds), tornando o desempenho reportado mais representativo. Complementarmente, reservou-se um hold-out estratificado de 20% (`random_state=42`) para matriz de confusão, Precision, Recall, F1-Score, curva ROC e AUC do modelo final, após seleção de hiperparâmetros no conjunto de treino via GridSearchCV com `scoring=recall`.

Pré-processamento: zeros em Glucose, BloodPressure, SkinThickness, Insulin e BMI foram interpretados como ausências (não como valores clínicos) e imputados pela mediana. Imputação e, no KNN, normalização Min-Max foram encapsuladas em Pipeline do scikit-learn, ajustadas apenas nos folds de treino, prevenindo vazamento.




Figura 1: Quantidade de zeros tratados como valores ausentes nas variáveis clínicas do Pima Indians Diabetes.

3. Engenharia e Seleção de Modelos

3.1 Árvores de Decisão

A impureza dos nós foi avaliada por Índice de Gini e Entropia de Shannon: ambos medem homogeneidade da classe e guiam a escolha do atributo de divisão que mais reduz a impureza.

O Gini tende a favorecer partições com classes majoritárias mais puras; a Entropia penaliza mais misturas equilibradas. A restrição de profundidade (`max_depth`) e o mínimo de amostras por folha (`min_samples_leaf`) atuam como regularização / pós-poda, limitando a capacidade de memorizar o treino e reduzindo overfitting — especialmente relevante em dados clínicos ruidosos e com n moderado. O melhor arranjo encontrado foi `criterion=gini`, `max_depth=4`, `min_samples_leaf=20`.

3.2 Naive Bayes

Optou-se pelo Naive Bayes Gaussiano, adequado a atributos contínuos; o Multinomial é voltado a contagens/frequências (ex.: texto) e não casa com o perfil do Pima. A hipótese de independência condicional dos atributos, dadas as classes, é frequentemente violada em dados clínicos (ex.: glicose correlacionada a IMC e idade). Na prática, essa simplificação pode degradar as estimativas de probabilidade, mas o classificador permanece competitivo quando as margens de decisão são favoráveis. Ajuste fino de `var_smoothing` teve impacto marginal; o Recall médio no CV ficou em 0,601.

3.3 KNN

O KNN é sensível à escala: variáveis com maior amplitude (ex.: Insulina) dominariam a distância sem normalização. Aplicou-se Min-Max para mapear cada atributo ao intervalo $[0,1]$. O hiperparâmetro K controla o compromisso viés–variância: K pequeno produz fronteiras irregulares e maior sensibilidade a ruído; K maior suaviza a decisão. A métrica Euclidiana enfatiza diferenças globais em todas as dimensões; a Manhattan é mais robusta a desvios em poucas coordenadas. O melhor conjunto foi $K=5$, métrica euclidiana e pesos uniformes.

4. Avaliação de Performance

A Tabela 1 resume o desempenho médio ($\pm$ desvio) no Stratified 10-Fold. A Árvore de Decisão liderou em Recall ($0,675 \pm 0,133$), métrica prioritária do Dr. Arnaldo, com AUC competitiva ($0,813 \pm 0,052$). Naive Bayes e KNN apresentaram Recall inferior, embora a acurácia dos três fique em faixa semelhante ($\sim 0,74\text{--}0,75$), ilustrando por que a acurácia sozinha é insuficiente em cenário clínico desbalanceado.

Modelo	Acurácia	Precision	Recall	F1	AUC
Árvore de Decisão	$0,741 \pm 0,05$	$0,640 \pm 0,10$	$0,675 \pm 0,13$	$0,642 \pm 0,06$	$0,813 \pm 0,05$
Naive Bayes	$0,746 \pm 0,06$	$0,661 \pm 0,12$	$0,601 \pm 0,11$	$0,622 \pm 0,09$	$0,813 \pm 0,06$
KNN	$0,750 \pm 0,06$	$0,654 \pm 0,10$	$0,612 \pm 0,09$	$0,631 \pm 0,09$	$0,794 \pm 0,06$

Tabela 1: Métricas médias ($\pm$ desvio) na validação cruzada estratificada ($K=10$) após otimização orientada ao Recall.




Figura 2: Comparativo dos modelos na validação cruzada estratificada (K=10).

No hold-out (154 amostras; 54 diabéticas), a Árvore alcançou Precision=0,696, Recall=0,722, F1=0,709 e AUC=0,805, com matriz TN=83, FP=17, FN=15 e TP=39. Ou seja, 15 pacientes diabéticos não foram sinalizados — desempenho superior ao Naive Bayes (FN=20) e ao KNN (FN=24) no mesmo particionamento. O Recall permanece a métrica-chave: mede a fração de doentes corretamente identificados e, portanto, a capacidade de evitar o erro clinicamente mais grave.




Figura 3: Matriz de confusão da Árvore de Decisão no conjunto de teste.




Figura 4: Curva ROC da Árvore de Decisão (AUC = 0,805).

Em termos práticos para a diretoria: uma AUC de 0,85 significaria que, em aproximadamente 85% dos pares formados por um paciente doente e um saudável escolhidos ao acaso, o modelo atribui escore maior ao paciente doente — evidência de boa capacidade de ranqueamento diagnóstico. No experimento, a Árvore atingiu AUC 0,805 (próxima a esse patamar ilustrativo), enquanto Naive Bayes e KNN ficaram em 0,765 e 0,774, respectivamente (Figura 5).




Figura 5: Curvas ROC dos três modelos no hold-out estratificado.




Figura 6: Matrizes de confusão comparativas no conjunto de teste.

5. Conclusão

Recomenda-se a Árvore de Decisão para produção no cenário da MedTech Solutions. Ela apresentou o melhor Recall na validação cruzada e no hold-out, reduzindo falsos negativos em relação às alternativas, com AUC competitiva. Do ponto de vista de governança em saúde, a árvore oferece interpretabilidade intrínseca (regras explícitas de decisão), favorecendo auditoria clínica e explicabilidade regulatória — vantagem frente ao KNN (baseado em instâncias) e ao Naive Bayes (probabilidades sob hipótese forte de independência). O trade-off entre transparência e capacidade preditiva, neste dataset e sob a restrição de minimizar FN, favorece a árvore regularizada (profundidade limitada), que evita sobreajuste sem abrir mão de desempenho.

Limitações: o Pima é relativamente pequeno e datado; zeros imputados (especialmente Insulina e SkinThickness) introduzem incerteza; e o limiar de decisão padrão (0,5) pode ser recalibrado para elevar ainda mais o Recall, às custas de Precision. Como próximos passos, sugerem-se calibração de probabilidade, análise de custo clínico assimétrico e validação externa em coortes contemporâneas antes da integração definitiva ao fluxo de telemedicina.

Referências

Materiais disponibilizados pelo professor.