

Caso 01 - IA e ciência de dados na saúde

Artur Borba Santos^{a,b,c}, Jesus Gabriel Leiva^{a,b,d}

^a Especialização em Ciência de Dados e Inteligência Artificial, Universidade de Marília (UNIMAR), Marília, SP, Brasil

^b Bacharelado em Ciência da Computação, Centro Universitário Eurípides de Marília (UNIVEM), Marília, SP, Brasil

^c Autor para correspondência: arturborba02@gmail.com

^d Autor para correspondência: jesusbrielleiva1@gmail.com

Resumo

O presente trabalho atende ao desafio proposto pela MedTech Solutions para o desenvolvimento de um modelo de classificação robusto visando a detecção precoce de diabetes. Utilizando o dataset Pima Indians Diabetes, estruturou-se um experimento comparativo envolvendo Árvores de Decisão, Naive Bayes e K-Nearest Neighbors (KNN). O foco metodológico recaiu na minimização de falsos negativos, críticos em diagnósticos de telemedicina. Aplicou-se validação cruzada estratificada K-Fold (K=10), com imputação de valores inválidos (zeros clínicos) e normalização Min-Max encapsuladas em Pipelines para evitar vazamento de informação. Os resultados indicaram que a Árvore de Decisão com **pós-poda** (cost-complexity pruning, `ccp_alpha=0.01`) obteve o maior Recall médio na validação cruzada ($0,661 \pm 0,175$), mantendo interpretabilidade intrínseca, sendo a escolha recomendada para produção no setor clínico — com a ressalva de variância elevada e de o Naive Bayes apresentar AUC ligeiramente superior.

Abstract

This work addresses the challenge proposed by MedTech Solutions to develop a robust classification model for early diabetes detection. Using the Pima Indians Diabetes dataset, a comparative experiment was structured involving Decision Trees, Naive Bayes, and K-Nearest Neighbors (KNN). The methodological focus was on minimizing false negatives, which are critical in telemedicine diagnoses. Stratified K-Fold cross-validation (K=10) was applied, with invalid clinical zeros imputed and Min-Max scaling placed inside Pipelines to prevent data leakage. Results indicated that the Decision Tree with post-pruning (`ccp_alpha=0.01`) achieved the highest mean Recall in cross-validation (0.661 ± 0.175) while preserving intrinsic interpretability, being the recommended production choice — noting high variance and a slightly higher AUC for Naive Bayes.

Palavras-chave: Machine Learning, Telemedicina, Árvores de Decisão, Naive Bayes, K-Nearest Neighbors, K-Fold.

1. Metodologia de Validação

Considerando a natureza finita do conjunto de dados Pima Indians Diabetes (768 pacientes; ~65% classe negativa e ~35% positiva), optou-se pelo **Stratified K-Fold Cross Validation** com K=10 [1]. A estratificação preserva a proporção das classes em cada fold, o que é especialmente relevante em dados clínicos desbalanceados. A escolha K=10 é um padrão consolidado na literatura para equilibrar viés e variância na estimativa do erro de generalização. Uma divisão holdout única poderia produzir partições atípicas; o uso de 10 partições torna o desempenho aferido mais representativo e menos dependente de um particionamento arbitrário. Antes da modelagem, zeros inválidos em Glucose, BloodPressure, SkinThickness, Insulin e BMI foram tratados como missing e imputados pela mediana **somente no conjunto de treino de cada fold**, via Pipeline, evitando vazamento de informação.

2. Engenharia e Seleção de Modelos

A modelagem requer algoritmos transparentes e capazes de lidar com variáveis clínicas predominantemente contínuas (glicose, pressão, IMC) e contagens (gestações), sob o requisito de minimizar falsos negativos.

Árvores de Decisão

Para a construção dos nós, utilizou-se o **Índice de Gini** (`criterion='gini'`) como medida de impureza, selecionando o atributo que melhor separa as classes a cada divisão. Árvores profundas tendem ao overfitting; por isso avaliaram-se duas estratégias distintas de regularização: (i) **pré-poda**, restringindo a profundidade máxima (`max_depth=5`), o que interrompe o crescimento antes da memorização excessiva; e (ii) **pós-poda** por cost-complexity pruning (`ccp_alpha=0.01`), na qual a árvore pode crescer e, em seguida, subárvores de baixo ganho são removidas [2]. Essa distinção é importante: limitar profundidade não é pós-poda; são mecanismos complementares de controle de complexidade.

Naive Bayes

Empregou-se o Naive Bayes **Gaussiano** em vez do Multinomial, pois as principais variáveis (pressão arterial, glicose, IMC, insulina) são contínuas; o Multinomial é mais adequado a contagens/discretizações tipicamente textuais. A fragilidade do modelo está na suposição de independência condicional entre atributos, frequentemente violada em dados clínicos (ex.: correlação entre IMC e insulina). Na prática, isso pode gerar excesso de confiança ao ponderar evidências correlacionadas como se fossem independentes [3]. Ainda assim, o classificador permanece competitivo em AUC neste dataset.

K-Nearest Neighbors (KNN)

O KNN é sensível à escala; por isso a normalização **Min-Max** foi aplicada apenas neste modelo, dentro do Pipeline (ajuste exclusivo no treino de cada fold). Sem esse pré-processamento, atributos de maior magnitude dominariam a distância. Além da configuração baseline ($K=5$, métrica euclidiana), executou-se um grid com $K \in \{3, 5, 7, 9, 11\}$ e métricas euclidiana vs. Manhattan, otimizando Recall. A melhor configuração foi **$K=9$ com distância euclidiana** (Recall CV $\approx 0,616$). Valores muito baixos de K aumentam sensibilidade a ruído e risco de falsos negativos pontuais; Manhattan tende a produzir fronteiras mais ortogonais, enquanto a euclidiana gera contornos mais suaves no espaço normalizado.

3. Avaliação de Performance

Em telemedicina, o risco das métricas é assimétrico: falsos positivos geram custos operacionais, mas falsos negativos implicam liberar paciente doente sem diagnóstico. Assim, o **Recall (sensibilidade)** foi a métrica de prioridade para seleção do modelo. A tabela a seguir resume a média $\pm$ desvio na validação cruzada estratificada ($K=10$).

Decision Tree (pré-poda): Recall $0,637 \pm 0,145$; Precision $0,675 \pm 0,106$; F1 $0,643 \pm 0,093$; AUC $0,786 \pm 0,070$.

Decision Tree (pós-poda): Recall **$0,661 \pm 0,175$** ; Precision $0,655 \pm 0,110$; F1 $0,634 \pm 0,093$; AUC $0,793 \pm 0,059$.

Naive Bayes: Recall $0,601 \pm 0,108$; Precision $0,661 \pm 0,122$; F1 $0,622 \pm 0,088$; AUC **$0,813 \pm 0,057$** .

KNN ($K=5$, euclidiana): Recall $0,612 \pm 0,090$; Precision $0,654 \pm 0,104$; F1 $0,631 \pm 0,092$; AUC $0,794 \pm 0,062$.

Pelo critério clínico de Recall, a **Árvore com pós-poda** foi selecionada como melhor modelo. Em holdout estratificado 70/30 (somente para visualização e métricas pontuais), esse modelo obteve Precision 0,708; Recall 0,568; F1 0,630; Accuracy 0,766. A matriz de confusão correspondente foi TN=131, FP=19, FN=35, TP=46 — evidenciando que ainda há falsos negativos relevantes, coerente com a alta variância do Recall no CV.




Figura 1. Matriz de confusão do melhor modelo em Recall no CV (Decision Tree com pós-poda) no holdout 30%.

As curvas ROC no holdout mostraram $AUC \approx 0,75$ (DT pré-poda), $0,77$ (DT pós-poda), $0,80$ (Naive Bayes) e $0,78$ (KNN). O Naive Bayes manteve a melhor ordenação de risco (AUC), enquanto a árvore pós-podada priorizou Recall no CV e oferece regras interpretáveis. Em termos práticos para a diretoria: uma AUC de $0,85$ significaria que, ao sortear aleatoriamente um paciente diabético e um saudável, o sistema atribuiria escore de risco maior ao paciente doente em cerca de 85% das vezes. No experimento corrigido, as AUCs situam-se aproximadamente na faixa $0,79$ – $0,81$ no CV (e $\sim 0,75$ – $0,80$ no holdout), indicando discriminação útil, porém abaixo do limiar ilustrativo de $0,85$ — o que reforça a necessidade de monitoramento contínuo em produção.




Figura 2. Curvas ROC dos modelos comparados no holdout estratificado 70/30.

4. Conclusão

Com base nas validações empíricas no dataset Pima, recomenda-se a **Árvore de Decisão com pós-poda** (`ccp_alpha=0.01`, critério Gini) para a plataforma da MedTech Solutions. A escolha pondera: (i) o melhor Recall médio no Stratified K-Fold, alinhado à minimização de falsos negativos; e (ii) a interpretabilidade intrínseca das regras, exigência de explicabilidade e segurança no setor de saúde — evitando soluções puramente caixa-preta. O Naive Bayes permanece alternativa competitiva em AUC, mas com menor transparência clínica das decisões. Ressalta-se a variância do Recall e o gap entre CV e holdout, indicando que o modelo deve ser acompanhado com recalibragem e, se necessário, limiares de decisão ajustados ao custo assimétrico de falsos negativos.

Referências

- [1] S. Arlot, A. Celisse, "Cross-validation procedures for model selection", *Statistics Surveys* 4 (2010) 40–79.
- [2] L. Breiman, J. Friedman, R. Olshen, C. Stone, "Classification and Regression Trees", Wadsworth and Brooks, Monterey, CA, 1984.
- [3] I. Rish, "An empirical study of the naive Bayes classifier", *IJCAI 2001 Workshop on Empirical Methods in Artificial Intelligence*, 2001.